


Introducción a





Manejo básico de datos

Data.table

Combinación y Reestructuración

1. Combinación de bases de datos (*rbind*)
2. Estratificación de bases de datos (*split*)
3. Cruce de bases de datos (*merge*)
4. Reestructuración (long – wide format)

Data.table

-Instalamos y cargamos la librería data.table

```
install.packages("data.table")  
  
library("data.table")
```


Estructura de un data.table

```
DT[i, j, by]  
  
## R:           i           j           by  
## SQL: where | order by   select | update group by
```

1. Combinación de bases de datos

Combinando data.tables

```
DF1=data.table(id="Luke Skywalker",altura=172,color.ojos="azul")  
DF2=data.table(id="Darth Vader",altura=202,color.ojos="amarillo")  
DF3=data.table(id="Leia Organa",altura=150,color.ojos="marrón")
```

 `rbind(DF1,DF2,DF3)`

	id	altura	color.ojos
	<char>	<num>	<char>
1:	Luke Skywalker	172	azul
2:	Darth Vader	202	amarillo
3:	Leia Organa	150	marrón

Ejercicio

Une las siguientes bases de datos:

```
datos.hombres=subset(datos,sexo=="Hombre",select=c(sexo,peso))  
  
str(datos.hombres)
```

```
Classes 'data.table' and 'data.frame': 100 obs. of  2 variables:  
 $ sexo: chr  "Hombre" "Hombre" "Hombre" "Hombre" ...  
 $ peso: num  79.2 80.8 80.8 79.8 80.7 ...  
- attr(*, ".internal.selfref")=<externalptr>
```

```
datos.mujeres=subset(datos,sexo=="Mujer",select=c(sexo,peso))  
  
str(datos.mujeres)
```

```
Classes 'data.table' and 'data.frame': 100 obs. of  2 variables:  
 $ sexo: chr  "Mujer" "Mujer" "Mujer" "Mujer" ...  
 $ peso: num  59.6 60 61.3 60.7 60.1 ...  
- attr(*, ".internal.selfref")=<externalptr>
```

Une las siguientes bases de datos:

```
datos.hombres=subset(datos, sexo=="Hombre", select=c(sexo, peso))  
  
str(datos.hombres)
```

```
Classes 'data.table' and 'data.frame': 100 obs. of  2 variables:  
 $ sexo: chr  "Hombre" "Hombre" "Hombre" "Hombre" ...  
 $ peso: num  79.2 80.8 80.8 79.8 80.7 ...  
- attr(*, ".internal.selfref")=<externalptr>
```

```
datos.mujeres=subset(datos, sexo=="Mujer", select=c(sexo, peso))  
  
str(datos.mujeres)
```

```
Classes 'data.table' and 'data.frame': 100 obs. of  2 variables:  
 $ sexo: chr  "Mujer" "Mujer" "Mujer" "Mujer" ...  
 $ peso: num  59.6 60 61.3 60.7 60.1 ...  
- attr(*, ".internal.selfref")=<externalptr>
```

Solución:

```
rbind(datos.mujeres, datos.hombres)
```

2. Estratificación de bases de datos (split)

Operación inversa a la combinación

```
temp=subset(datos,select=c(sexo,estado.civil,peso))
```

```
Estratos = split(temp,by="sexo")
```

```
str(estratos)
```

List of 2

```
$ Mujer :Classes 'data.table' and 'data.frame':
```

```
100 obs. of 3 variables:
```

```
..$ sexo      : chr [1:100] "Mujer" "Mujer" "Mujer" "Mujer" ...
```

```
..$ estado.civil: chr [1:100] "Casado" "Soltero" "Soltero" "Divorciado" ...
```

```
..$ peso      : num [1:100] 59.6 60 61.3 60.7 60.1 ...
```

```
..- attr(*, ".internal.selfref")=<externalptr>
```

```
$ Hombre:Classes 'data.table' and 'data.frame':
```

```
100 obs. of 3 variables:
```

```
..$ sexo      : chr [1:100] "Hombre" "Hombre" "Hombre" "Hombre" ...
```

```
..$ estado.civil: chr [1:100] "Casado" "Divorciado" "Divorciado" "Casado" ...
```

```
..$ peso      : num [1:100] 79.2 80.8 80.8 79.8 80.7 ...
```

```
..- attr(*, ".internal.selfref")=<externalptr>
```

2. Estratificación de bases de datos (split)

Estratificando de acuerdo a varias variables

```
temp=subset(datos,select=c(sexo,estado.civil,peso))  
estratos=split(temp, by=c("sexo","estado.civil"))  
str(estratos[1:2])
```

List of 2

```
$ Mujer.Casado :Classes 'data.table' and 'data.frame':  
  20 obs. of  3 variables:  
 ..$ sexo          : chr [1:20] "Mujer" "Mujer" "Mujer" "Mujer" ...  
 ..$ estado.civil: chr [1:20] "Casado" "Casado" "Casado" "Casado" ...  
 ..$ peso          : num [1:20] 59.6 60.3 58 58.4 60.6 ...  
 ..- attr(*, ".internal.selfref")=<externalptr>  
$ Mujer.Soltero:Classes 'data.table' and 'data.frame':  
  44 obs. of  3 variables:  
 ..$ sexo          : chr [1:44] "Mujer" "Mujer" "Mujer" "Mujer" ...  
 ..$ estado.civil: chr [1:44] "Soltero" "Soltero" "Soltero" "Soltero" ...  
 ..$ peso          : num [1:44] 60 61.3 60.4 57.9 60.4 ...  
 ..- attr(*, ".internal.selfref")=<externalptr>
```

3. Cruce de bases de datos (merge)

Mismos registros con diferentes variables

```
DF1=data.table(id=c("C-3P0", "R2-D2", "Chewbacca"), altura=c(167,96,228))
DF2=data.table(id=c("C-3P0", "R2-D2"), peso=c(75,32))
```

```
merge(DF1,DF2,by="id")
```

Key: <id>

	id	altura	peso
	<char>	<num>	<num>
1:	C-3P0	167	75
2:	R2-D2	96	32

```
merge(DF1,DF2,by="id",all.x=TRUE)
```

Key: <id>

	id	altura	peso
	<char>	<num>	<num>
1:	C-3P0	167	75
2:	Chewbacca	228	NA
3:	R2-D2	96	32

Ejercicio



Juntar las siguientes bases de datos

```
socio.demo=subset(datos, select=ID:nivel.estudios)  
basal=subset(datos, select=c(ID,peso:diabetes))
```

Ejercicio

Juntar las siguientes bases de datos

```
socio.demo=subset(datos, select=ID:nivel.estudios)
basal=subset(datos, select=c(ID,peso:diabetes))
```

Solución:

```
merge(socio.demo,basal,by="ID",all=TRUE)
```

Key: <ID>

	ID	edad	sexo	estado.civil	nivel.estudios	peso	altura	fumador	diabetes
	<num>	<num>	<char>	<char>	<char>	<num>	<num>	<char>	<char>
1:	1	21	Hombre	Soltero	Alto	80.23501	171.0138	No	No
2:	2	13	Mujer	Soltero	Alto	61.92519	150.3046	Si	No
3:	3	4	Hombre	Soltero	Alto	80.13242	168.7405	No	Si
4:	4	9	Mujer	Soltero	Alto	61.17363	150.2084	Si	No
5:	5	81	Hombre	Soltero	Alto	80.11593	168.1224	No	No

196:	196	44	Hombre	Casado	Alto	79.43454	168.3474	Si	No
197:	197	85	Mujer	Casado	Medio	59.37053	149.6450	Si	No
198:	198	53	Mujer	Soltero	Bajo	61.24236	150.8138	Si	No
199:	199	7	Hombre	Soltero	Bajo	81.32345	169.9339	Si	No
200:	200	29	Hombre	Casado	Bajo	79.20674	168.9795	No	Si

4. Restrukturación (long – wide)



Transformación a formato wide

```
set.seed(123)
```

```
datos[, presion_sistolica := round(rnorm(.N, mean = 120, sd = 15))]  
datos[, presion_diastolica := round(rnorm(.N, mean = 80, sd = 10))]
```

```
datos_filt<-subset(datos,select=c(ID:sexo,presion_sistolica,  
presion_diastolica))
```

	ID	edad	sexo	presion_sistolica	presion_diastolica
	<num>	<num>	<char>	<num>	<num>
1:	137	37	Mujer	112	102
2:	174	85	Mujer	117	93
3:	200	29	Hombre	143	77
4:	23	13	Hombre	121	85
5:	39	49	Hombre	122	76

196:	42	72	Mujer	150	95
197:	145	50	Hombre	129	72
198:	57	41	Hombre	101	88
199:	169	44	Mujer	111	67
200:	143	54	Mujer	102	76

4. Restrukturación (long – wide)

Formato wide

```
wide<-melt(datos_filt,id=1:3, variable.name="presion",value.name="mmHg")
```

	ID	edad	sexo		presion	mmHg
	<num>	<num>	<char>		<fctr>	<num>
1:	137	37	Mujer	presion_sistolica		112
2:	174	85	Mujer	presion_sistolica		117
3:	200	29	Hombre	presion_sistolica		143
4:	23	13	Hombre	presion_sistolica		121
5:	39	49	Hombre	presion_sistolica		122

396:	42	72	Mujer	presion_diastolica		95
397:	145	50	Hombre	presion_diastolica		72
398:	57	41	Hombre	presion_diastolica		88
399:	169	44	Mujer	presion_diastolica		67
400:	143	54	Mujer	presion_diastolica		76

4. Restrukturación (long – wide)

Volvemos al formato long

```
long<-dcast(wide, ID+edad+sexo ~presion,value.var="mmHg")
```

Key: <ID, edad, sexo>

	ID	edad	sexo	presion_sistolica	presion_diastolica
	<num>	<num>	<char>	<num>	<num>
1:	1	21	Hombre	130	84
2:	2	13	Mujer	113	71
3:	3	4	Hombre	110	67
4:	4	9	Mujer	131	78
5:	5	81	Hombre	122	79

196:	196	44	Hombre	112	75
197:	197	85	Mujer	148	75
198:	198	53	Mujer	128	91
199:	199	7	Hombre	130	74
200:	200	29	Hombre	143	77