


Introducción a





Manejo básico de datos

Data.table

Filtro y Cálculo

1. Introducción data.table
2. Cálculo de columnas (:=)
3. Cálculo agrupado (*by*)
4. Filtro (*subset*)

1. Introducción data.table

Instalamos y cargamos la librería data.table

```
install.packages("data.table")  
library("data.table")
```

Estructura de un data.table

```
DT[i, j, by]  
  
## R:           i           j           by  
## SQL: where | order by   select | update group by
```

1. Introducción data.table

```
DF = data.frame(  
  id = c("Luke Skywalker", "Darth Vader", "Leia Organa", "C-3P0", "R2-D2"),  
  peso = c(77, 136, 49, 75, 32),  
  altura = c(172, 202, 150, 167, 96),  
  especie= c("Humana", "Humana", "Humana", "Droid", "Droid"))
```

	id	peso	altura	especie
1	Luke Skywalker	77	172	Humana
2	Darth Vader	136	202	Humana
3	Leia Organa	49	150	Humana
4	C-3P0	75	167	Droid
5	R2-D2	32	96	Droid

1. Introducción data.table

```
DT=data.table(DF) #Convertimos el objeto DF en un data.table
```

DT

Data.table

	id	peso	altura	especie
	<char>	<num>	<num>	<char>
1:	Luke Skywalker	77	172	Humana
2:	Darth Vader	136	202	Humana
3:	Leia Organa	49	150	Humana
4:	C-3PO	75	167	Droid
5:	R2-D2	32	96	Droid

Data.frame

	id	peso	altura	especie
1	Luke Skywalker	77	172	Humana
2	Darth Vader	136	202	Humana
3	Leia Organa	49	150	Humana
4	C-3PO	75	167	Droid
5	R2-D2	32	96	Droid

Ejercicio

A partir de la siguiente base de datos:

```
load("~datos.curso1.RData")
```

```
'data.frame':  200 obs. of  11 variables:
 $ ID          : num  137 174 200 23 39 90 40 115 72 27 ...
 $ edad        : num  37 85 29 13 49 12 85 31 39 70 ...
 $ sexo        : chr   "Mujer" "Mujer" "Hombre" "Hombre" ...
 $ estado.civil : chr   "Casado" "Soltero" "Casado" "Divorciado" ...
 $ nivel.estudios : chr   "Bajo" "Alto" "Bajo" "Alto" ...
 $ peso        : num  59.6 60 79.2 80.8 80.8 ...
 $ altura      : num  151 149 169 171 171 ...
 $ fumador     : chr   "No" "No" "No" "Si" ...
 $ diabetes    : chr   "No" "Si" "Si" "Si" ...
 $ cancer.mama  : chr   "Si" "No" "Si" NA ...
 $ cancer.prostata: chr   NA NA "Si" "Si" ...
```

Convertir en data.table y visualizarlo

Ejercicio

```
datos_dt<-data.table(datos) # Convertimos nuestros datos en data.table
```

```
datos_dt
```

	ID	edad	sexo	estado.civil	nivel.estudios	peso	altura	fumador	diabetes	cancer.mama	cancer.prostata
	<num>	<num>	<char>	<char>	<char>	<num>	<num>	<char>	<char>	<char>	<char>
1:	137	37	Mujer	Casado	Bajo	59.58221	150.7163	No	No	Si	<NA>
2:	174	85	Mujer	Soltero	Alto	59.95427	149.2075	No	Si	No	<NA>
3:	200	29	Hombre	Casado	Bajo	79.20674	168.9795	No	Si	Si	Si
4:	23	13	Hombre	Divorciado	Alto	80.78347	171.1568	Si	Si	<NA>	Si
5:	39	49	Hombre	Divorciado	Bajo	80.76036	170.5682	Si	Si	<NA>	No

196:	42	72	Mujer	Divorciado	Bajo	60.31752	149.2896	No	No	Si	<NA>
197:	145	50	Hombre	Divorciado	Medio	78.75054	169.5396	No	Si	<NA>	Si
198:	57	41	Hombre	Soltero	Medio	79.45077	168.4157	No	No	<NA>	No
199:	169	44	Mujer	Soltero	Bajo	59.69171	149.0113	Si	No	No	<NA>
200:	143	54	Mujer	Divorciado	Medio	61.02373	150.8797	Si	Si	Si	<NA>

1. Introducción data.table

Selección de filas “i”

1. Seleccionar un número concreto de filas

```
datos_dt[1:10]
```

NOTA:

En el caso de data.table no hace falta indicarle al final con una “,” que se trata de filas.

2. Selección de filas mediante condición

```
datos_dt[edad>50 & sexo=="Mujer" & estado.civil=="Casado"]
```

	ID	edad	sexo	estado.civil	nivel.estudios	peso	altura	fumador	diabetes	cancer.mama	cancer.prostata
	<num>	<num>	<char>	<char>	<char>	<num>	<num>	<char>	<char>	<char>	<char>
1:	44	74	Mujer	Casado	Medio	60.33449	148.2137	No	Si	Si	<NA>
2:	122	68	Mujer	Casado	Alto	61.06287	149.0318	No	No	Si	<NA>
3:	47	81	Mujer	Casado	Bajo	61.21061	149.0885	No	Si	Si	<NA>
4:	92	54	Mujer	Casado	Bajo	59.50153	150.7325	No	No	Si	<NA>
5:	71	69	Mujer	Casado	Bajo	61.65951	150.3241	Si	No	Si	<NA>
6:	197	85	Mujer	Casado	Medio	59.37053	149.6450	Si	No	Si	<NA>
7:	107	52	Mujer	Casado	Medio	59.75749	151.8687	Si	No	Si	<NA>
8:	6	66	Mujer	Casado	Alto	58.91967	150.4848	No	Si	No	<NA>
9:	52	77	Mujer	Casado	Medio	59.57056	149.4516	No	No	Si	<NA>

1. Introducción data.table

3. Ordenar filas

```
ans<-datos_dt[order(peso)]
```

	ID	edad	sexo	estado.civil	nivel.estudios	peso	altura	fumador	diabetes	cancer.mama	cancer.prostata
	<num>	<num>	<char>	<char>	<char>	<num>	<num>	<char>	<char>	<char>	<char>
1:	104	6	Mujer	Divorciado	Medio	56.56025	148.9580	No	Si	Si	<NA>
2:	67	75	Mujer	Soltero	Bajo	57.30206	149.7838	No	Si	Si	<NA>
3:	195	55	Mujer	Divorciado	Medio	57.58416	151.1169	No	No	No	<NA>
4:	93	46	Mujer	Soltero	Bajo	57.88490	148.9322	Si	No	Si	<NA>
5:	148	6	Mujer	Soltero	Bajo	57.93049	149.7306	No	No	Si	<NA>

196:	34	5	Hombre	Casado	Alto	81.60512	169.8919	Si	No	<NA>	Si
197:	11	30	Hombre	Divorciado	Alto	81.73699	169.1571	Si	Si	<NA>	Si
198:	97	32	Hombre	Divorciado	Bajo	81.92957	171.1341	No	No	<NA>	No
199:	185	9	Hombre	Divorciado	Alto	82.13408	169.4244	No	Si	<NA>	Si
200:	105	57	Hombre	Divorciado	Bajo	82.28081	170.0166	No	Si	<NA>	Si

```
ans<-datos_dt[order(peso, -sexo)]
```

	ID	edad	sexo	estado.civil	nivel.estudios	peso	altura	fumador	diabetes	cancer.mama	cancer.prostata
	<num>	<num>	<char>	<char>	<char>	<num>	<num>	<char>	<char>	<char>	<char>
1:	104	6	Mujer	Divorciado	Medio	56.56025	148.9580	No	Si	Si	<NA>
2:	67	75	Mujer	Soltero	Bajo	57.30206	149.7838	No	Si	Si	<NA>
3:	195	55	Mujer	Divorciado	Medio	57.58416	151.1169	No	No	No	<NA>
4:	93	46	Mujer	Soltero	Bajo	57.88490	148.9322	Si	No	Si	<NA>
5:	148	6	Mujer	Soltero	Bajo	57.93049	149.7306	No	No	Si	<NA>

196:	34	5	Hombre	Casado	Alto	81.60512	169.8919	Si	No	<NA>	Si
197:	11	30	Hombre	Divorciado	Alto	81.73699	169.1571	Si	Si	<NA>	Si
198:	97	32	Hombre	Divorciado	Bajo	81.92957	171.1341	No	No	<NA>	No
199:	185	9	Hombre	Divorciado	Alto	82.13408	169.4244	No	Si	<NA>	Si
200:	105	57	Hombre	Divorciado	Bajo	82.28081	170.0166	No	Si	<NA>	Si

1. Introducción data.table

Selección de columnas "j"

```
ans<-datos_dt[,sexo]
```

Esto nos devuelve un vector !!

```
[1] "Mujer" "Mujer" "Hombre" "Hombre" "Hombre" "Hombre" "Hombre" "Mujer" "Mujer" "Hombre" "Mujer" "Hombre" "Mujer"
[14] "Mujer" "Mujer" "Mujer" "Mujer" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Mujer"
[27] "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Mujer" "Mujer" "Mujer" "Hombre" "Mujer" "Hombre" "Hombre"
[40] "Hombre" "Mujer" "Hombre" "Mujer" "Mujer" "Hombre" "Mujer" "Hombre" "Mujer" "Hombre" "Hombre" "Hombre" "Mujer"
[53] "Hombre" "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Mujer" "Mujer" "Hombre"
[66] "Hombre" "Mujer" "Mujer" "Hombre" "Mujer" "Hombre" "Mujer" "Mujer" "Hombre" "Mujer" "Hombre" "Mujer" "Mujer"
[79] "Mujer" "Hombre" "Mujer" "Hombre" "Mujer" "Mujer" "Mujer" "Mujer" "Mujer" "Mujer" "Hombre" "Mujer" "Mujer"
[92] "Mujer" "Hombre" "Hombre" "Hombre" "Mujer" "Hombre" "Hombre" "Hombre" "Mujer" "Mujer" "Hombre" "Hombre" "Hombre"
[105] "Hombre" "Mujer" "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Mujer" "Hombre" "Hombre"
[118] "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Mujer" "Mujer" "Hombre" "Hombre" "Hombre" "Mujer" "Hombre"
[131] "Hombre" "Hombre" "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Mujer"
[144] "Hombre" "Mujer" "Mujer" "Mujer" "Hombre" "Mujer" "Hombre" "Mujer" "Mujer" "Hombre" "Mujer" "Hombre" "Mujer"
[157] "Hombre" "Hombre" "Hombre" "Hombre" "Mujer" "Mujer" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Mujer" "Mujer"
[170] "Mujer" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Hombre" "Hombre" "Mujer" "Mujer" "Mujer" "Mujer" "Mujer"
[183] "Mujer" "Mujer" "Mujer" "Hombre" "Hombre" "Mujer" "Hombre" "Hombre" "Mujer" "Mujer" "Hombre" "Hombre" "Hombre"
[196] "Mujer" "Hombre" "Hombre" "Mujer" "Mujer"
```

```
ans<-datos_dt[,.(ID,sexo,edad,peso,altura)]
```

	ID	sexo	edad	peso	altura
	<num>	<char>	<num>	<num>	<num>
1:	137	Mujer	37	59.58221	150.7163
2:	174	Mujer	85	59.95427	149.2075
3:	200	Hombre	29	79.20674	168.9795
4:	23	Hombre	13	80.78347	171.1568
5:	39	Hombre	49	80.76036	170.5682

196:	42	Mujer	72	60.31752	149.2896
197:	145	Hombre	50	78.75054	169.5396
198:	57	Hombre	41	79.45077	168.4157
199:	169	Mujer	44	59.69171	149.0113
200:	143	Mujer	54	61.02373	150.8797

1. Introducción data.table

4. Renombrar columnas

```
ans<-datos_dt[,.(habito.tab=fumador, estatus.diab=diabetes)]
```

	habito.tab	estatus.diab
	<char>	<char>
1:	No	No
2:	No	Si
3:	No	Si
4:	Si	Si
5:	Si	Si

196:	No	No
197:	No	Si
198:	No	No
199:	Si	No
200:	Si	Si

2. Cálculo de columnas

`datos_dt[,imc := peso/(altura/100)^2] #Calculo del índice de masa corporal`

`datos_dt`

	ID	edad	sexo	estado.civil	nivel.estudios	peso	altura	fumador	diabetes	cancer.mama	cancer.prostata	imc
	<num>	<num>	<char>	<char>	<char>	<num>	<num>	<char>	<char>	<char>	<char>	<num>
1:	137	37	Mujer	Casado	Bajo	59.58221	150.7163	No	No	Si	<NA>	26.22986
2:	174	85	Mujer	Soltero	Alto	59.95427	149.2075	No	Si	No	<NA>	26.93015
3:	200	29	Hombre	Casado	Bajo	79.20674	168.9795	No	Si	Si	Si	27.73921
4:	23	13	Hombre	Divorciado	Alto	80.78347	171.1568	Si	Si	<NA>	Si	27.57618
5:	39	49	Hombre	Divorciado	Bajo	80.76036	170.5682	Si	Si	<NA>	No	27.75890

196:	42	72	Mujer	Divorciado	Bajo	60.31752	149.2896	No	No	Si	<NA>	27.06351
197:	145	50	Hombre	Divorciado	Medio	78.75054	169.5396	No	Si	<NA>	Si	27.39752
198:	57	41	Hombre	Soltero	Medio	79.45077	168.4157	No	No	<NA>	No	28.01129
199:	169	44	Mujer	Soltero	Bajo	59.69171	149.0113	Si	No	No	<NA>	26.88286
200:	143	54	Mujer	Divorciado	Medio	61.02373	150.8797	Si	Si	Si	<NA>	26.80633

3. Cálculo agrupado (by)

```

# IMC respecto a una referencia grupal

datos_dt[,exc.imc := imc/mean(imc), by=nivel.estudios]

datos_dt[,5:13]

```

	nivel.estudios	peso	altura	fumador	diabetes	cancer.mama	cancer.prostata	imc	exc.imc
	<char>	<num>	<num>	<char>	<char>	<char>	<char>	<num>	<num>
1:	Bajo	59.58221	150.7163	No	No	Si	<NA>	26.22986	0.9679328
2:	Alto	59.95427	149.2075	No	Si	No	<NA>	26.93015	0.9838119
3:	Bajo	79.20674	168.9795	No	Si	Si	Si	27.73921	1.0236308
4:	Alto	80.78347	171.1568	Si	Si	<NA>	Si	27.57618	1.0074126
5:	Bajo	80.76036	170.5682	Si	Si	<NA>	No	27.75890	1.0243575

196:	Bajo	60.31752	149.2896	No	No	Si	<NA>	27.06351	0.9986960
197:	Medio	78.75054	169.5396	No	Si	<NA>	Si	27.39752	1.0099899
198:	Medio	79.45077	168.4157	No	No	<NA>	No	28.01129	1.0326159
199:	Bajo	59.69171	149.0113	Si	No	No	<NA>	26.88286	0.9920299
200:	Medio	61.02373	150.8797	Si	Si	Si	<NA>	26.80633	0.9881962

Ejercicio

Partiendo de la base datos (datos_dt), realizar el mismo cálculo que en el ejemplo anterior, pero usando como referencia el IMC medio por sexo, estado civil y nivel de estudios.

	nivel.estudios	peso	altura	fumador	diabetes	cancer.mama	cancer.prostata	imc	exc.imc	exc.imc2
	<char>	<num>	<num>	<char>	<char>	<char>	<char>	<num>	<num>	<num>
1:	Bajo	59.58221	150.7163	No	No	Si	<NA>	26.22986	0.9679328	0.9816565
2:	Alto	59.95427	149.2075	No	Si	No	<NA>	26.93015	0.9838119	1.0024880
3:	Bajo	79.20674	168.9795	No	Si	Si	Si	27.73921	1.0236308	0.9937224
4:	Alto	80.78347	171.1568	Si	Si	<NA>	Si	27.57618	1.0074126	0.9916774
5:	Bajo	80.76036	170.5682	Si	Si	<NA>	No	27.75890	1.0243575	1.0045125

196:	Bajo	60.31752	149.2896	No	No	Si	<NA>	27.06351	0.9986960	1.0111110
197:	Medio	78.75054	169.5396	No	Si	<NA>	Si	27.39752	1.0099899	0.9852689
198:	Medio	79.45077	168.4157	No	No	<NA>	No	28.01129	1.0326159	1.0105011
199:	Bajo	59.69171	149.0113	Si	No	No	<NA>	26.88286	0.9920299	1.0174449
200:	Medio	61.02373	150.8797	Si	Si	Si	<NA>	26.80633	0.9881962	1.0079203

Ejercicio

Partiendo de la base datos (datos_dt), realizar el mismo cálculo que en el ejemplo anterior, pero usando como referencia el IMC medio por sexo, estado civil y nivel de estudios.

	nivel.estudios	peso	altura	fumador	diabetes	cancer.mama	cancer.prostata	imc	exc.imc	exc.imc2
	<char>	<num>	<num>	<char>	<char>	<char>	<char>	<num>	<num>	<num>
1:	Bajo	59.58221	150.7163	No	No	Si	<NA>	26.22986	0.9679328	0.9816565
2:	Alto	59.95427	149.2075	No	Si	No	<NA>	26.93015	0.9838119	1.0024880
3:	Bajo	79.20674	168.9795	No	Si	Si	Si	27.73921	1.0236308	0.9937224
4:	Alto	80.78347	171.1568	Si	Si	<NA>	Si	27.57618	1.0074126	0.9916774
5:	Bajo	80.76036	170.5682	Si	Si	<NA>	No	27.75890	1.0243575	1.0045125

196:	Bajo	60.31752	149.2896	No	No	Si	<NA>	27.06351	0.9986960	1.0111110
197:	Medio	78.75054	169.5396	No	Si	<NA>	Si	27.39752	1.0099899	0.9852689
198:	Medio	79.45077	168.4157	No	No	<NA>	No	28.01129	1.0326159	1.0105011
199:	Bajo	59.69171	149.0113	Si	No	No	<NA>	26.88286	0.9920299	1.0174449
200:	Medio	61.02373	150.8797	Si	Si	Si	<NA>	26.80633	0.9881962	1.0079203

Solucion:

```
datos_dt[,exc.imc2:=imc/mean(imc),
by=.(nivel.estudios,sexo,estado.civil)]
```

4. Filtro subset

```
datos_sub<-subset(datos_dt,sexo%in%"Mujer",  
select=c("ID","peso","altura","sexo"))
```

	ID	peso	altura	sexo
	<num>	<num>	<num>	<char>
1:	137	59.58221	150.7163	Mujer
2:	174	59.95427	149.2075	Mujer
3:	115	61.28985	150.0667	Mujer
4:	72	60.70871	150.4091	Mujer
5:	19	60.06984	149.5328	Mujer
6:	15	60.39387	150.7226	Mujer